Minería de Datos: Application Programming Interface (Sesión 10B)

Prof. Juan C. Correa, Ph.D.

Colegio de Estudios Superiores de Administración Bogotá - Colombia





Objetivo de Aprendizaje

En la sesión 10A estudiamos, a través de un ejercicio quiado y un taller, la técnica de web scrapina. En esta sesión, estudiaremos algunos de los fundamentos de una técnica semejante llamada Application Programming Interface (API). A través de un API, es posible recolectar datos disponibles en redes sociales de manera semi-automática. En esta sesión nos concentraremos en cómo usar la API de Twitter para recolectar datos frescos de los tweets de usuarios de Twitter. En la próxima sesión continuaremos con la idea de saber cómo extraer y quardar esos datos.



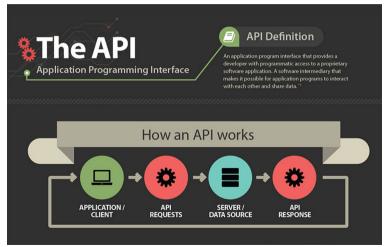
1

Insumos Preliminares



Insumo Conceptual:

Servidor Fuente de Datos (Sesión 3B) y Application Programming Interface (Chan, Chung, y Huang, 2019)







2

Caso de Estudio



CYBERPSYCHOLOGY, BEHAVIOR, AND SOCIAL NETWORKING Volume 20, Number 1, 2017 Mary Ann Liebert, Inc. DOI: 10.1089/cyber.2016.0402

Ideological Consumerism in Colombian Elections, 2015: Links Between Political Ideology, Twitter Activity, and Electoral Results

Juan C. Correa, PhD, and Jorge E. Camargo, PhD2

Abstract

Propagation of political ideologies in social networks has shown a substantial impact on voting behavior. Both the contents of the messages (the ideology) and the politicians' influence on their online audiences (their followers) have been associated with such an impact. In this study we evaluate which of these factors exerted a major role in deciding electoral results of the 2015 Colombian regional elections by evaluating the linguistic similarity of political ideologies and their influence on the Twitter sphere. The electoral results proved to be strongly associated with tweets and retweets and not with the linguistic content of their ideologies or politicians' followers in Twitter. Finally, sugerestions for new wavs to analyze electoral processes are discussed:

Keywords: Twitter, Colombian elections, ideological consumerism

(Correa y Camargo, 2017)







El **Consumismo Ideológico** ocurre cuando las decisiones individuales de apoyar o rechazar alguna acción (comprar, vender) son guiadas por ideales basados en principios éticos o morales.

¿Existe consumismo ideológico en las elecciones regionales de Colombia 2015? y de ser así ¿Cómo se evidencia tal fenómeno?



52 candidatos a gobernadores; 52 colecciones de tweets; 69.202 tweets; número promedio de tweets por candidato; número promedio de retweets por tweet por candidato; ideología política; similaridad lingüística entre ideologías; resultados electorales (número de votos recibidos).





En esta **matriz término-documento** se captan las relaciones entre las palabras (filas) que aparecen en cada mensaje tuiteado por cada candidato (columnas), cuya ideología política se expresa con un color específico.

| | Candidato 1 | Candidato 2 | Candidato 3 | |
|-----------|-------------|-------------|-------------|--|
| mejor | 1 | 0 | 1 | |
| educación | 1 | 1 | 0 | |
| para | 1 | 0 | 1 | |
| Colombia | 1 | 1 | 1 | |
| no | 0 | 1 | 0 | |
| merece | 0 | 1 | 0 | |
| mala | 0 | 1 | 0 | |
| empleo | 0 | 0 | 1 | |
| | | | | |



Si consideramos que todos los tuits de un candidato conforman un documento que se repsenta como un vector de 1 y 0, entonces su representación formal sería:

$$X_i = (X_{1,i}, X_{2,i}, X_{3,i}, ... X_{t,i})$$
 (1)

У

$$x_{t,i} = tft \cdot \frac{log|D|}{|t \in i|} \tag{2}$$

Donde, x es un tuit, tft es la frecuencia de aparición de la palabra t en el documento i, |D| es el número de tuits de un candidato y $log|D|/|t \in i|$ es el inverso de la frecuencia de los documentos que contienen la palabra t.

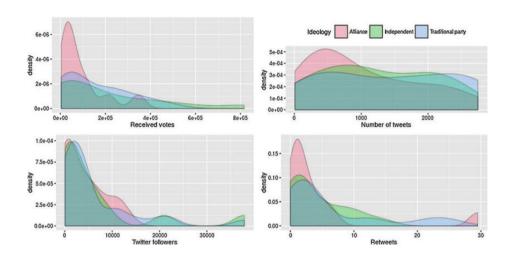


Asumiendo que $x_{t,i}$ se puede pintar en un espacio cartesiano, entonces la **semejanza lingüística** entre cualquier par de vectores se puede estimar como:

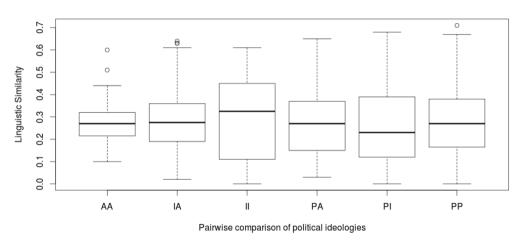
$$d(p,q) = \sqrt{(p-q)^2} \tag{3}$$

donde, d representa a la distancia Euclidea entre el conjunto de tuits publicados por el candidato p y el conjunto de tuits del candidato q

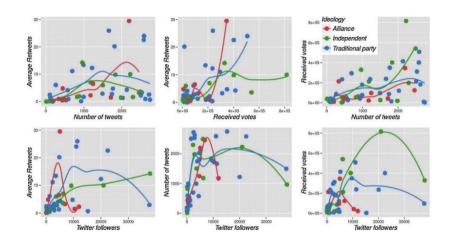














3

Pasos para usar una API

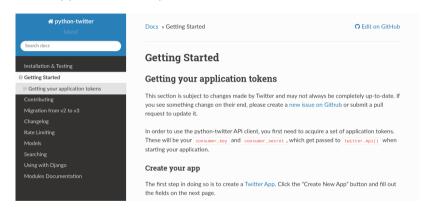




["RT @C3UNAM: This talk will show how machine learning, artificial intelligence, and natural language processing c an help to trace people's b.". 'RT @isidroaquillo: Ya se que debemos utilizar la cortesía académica y ser política mente correctos, pero ¿cómo actuar con un interlocutor ab...', '@cosnet bifi @BIFI Instituto @unizar @UccUnizar @ARA ID ES @GobAragon Congrats!', 'https://t.co/7jHt4A8JKJ', 'Wow. This interesting article by @ccabanac and colleague s presents a brand new perspective of scientific writing a., https://t.co/y26MRzZDPm', 'RT @MyScienceWork: An inter esting read in from Interdisciplinary Scientist @icorrean \nDoes limited access to publications really hinder sc i...'. 'RT @profiamesevans: The amazing Johan Chu and I published a piece out this week at PNAS (https://t.co/McjwkX BxyG) showing how the growing s...'. 'RT @PLOS: How Open is your research?\n\nTake our short guiz to find out your s core and get tips on how you can develop your #OpenScience skil...', 'Interesante lectura https://t.co/ySpogpimm8', 'https://t.co/Y9IHOIt6hB'. 'In our last paper, we revealed that the trust-sales relationship is not consistent at all in several Latin American... https://t.co/OAyF345ah5'. 'The Consistency of Trust-Sales Relationship in Latin Ame rican E-Commerce https://t.co/0lhBHYrnok'. 'Our last paper presents new evidence on the relationship between Econo mic Complexity, Economic Growth, and CO2 Emis., https://t.co/n4M8LCAVQL', 'RT @hadleywickham: Major updates to all tidyyerse cheat thanks to our intern @ayperny. Download them now! #rstats https://t.co/9Nl4tX9F3d'. 'RT @Bibliomet raF: The Invisible Citation Commons.\\\\nhttps://t.co/yiRPM0GdNj', 'RT @Piniisima: La evidencia más sólida de como trasciende un tuit de una red social poca representativa a una red nacional significativa: L..'. 'RT @Marek Kwiek: A reliable bibliometric picture of the post-Soviet world in science, 15 countries. Interesting!\n\nhttps://t.co/5m RdWNCdDN', 'El próximo 21 de Septiembre de 2021, estaré encantado de compartir algunas ideas en el Primer Simposio Internaciona... https://t.co/SURHkyeoTS'. 'RT @RibeiroHV: Our work "Association between productivity and journal imp act across disciplines and career age" has just been accepted for ... 'Our paper on the sci-hub effect has received a recent citation. This time from physical review research... https://t.co/3wkf0LTvGz']



Paso 1: Crear una App de Twitter leyendo el manual



https://python-twitter.readthedocs.io/en/latest/getting_started.html



Paso 1 (opción alternativa): Observe este video

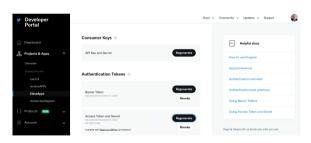


https://youtu.be/XQ6X5DYcdzA



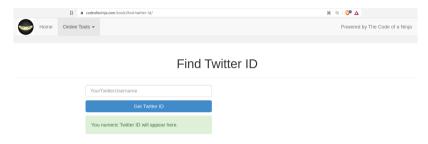
Paso 2: Tome nota de las credenciales de su API:

- 1 consumer_key
- 2 consumer_secret
- 3 access_token_key
- 4 access_token_secret





Paso 3: Consiga el ID numérico del usuario de Twitter cuyos datos quiere extraer.



https://codeofaninja.com/tools/find-twitter-id/



Paso 4: Tome nota del ID numérico y úselo en la sintaxis

@jcorrean

Get Twitter ID

Username: @jcorrean
Twitter Numeric ID: 106483037
Member since: January 19 2010, 18:16:44 PM

https://codeofaninja.com/tools/find-twitter-id/



Sugerencias para estudio adicional



https://developer.twitter.com/en/products/twitter-api/academic-research



Referencias I

- Chan, J., Chung, R., y Huang, J. (2019). *Python API Development Fundamentals*. Birmingham, UK: Packt Publishing.
- Correa, J. C., y Camargo, J. E. (2017). Ideological consumerism in colombian elections, 2015: Links between political ideology, twitter activity, and electoral results. *Cyberpsychology, Behavior, and Social Networking*, *20*(1), 37–43. doi: 10.1089/cyber.2016.0402



